

LLM 모델 비교·선정 최종 통합 분석 보고서

과업: 회의 메모 → 사내 공유용 회의록 자동 요약 / 3개 AI 분석 보고서 종합

1. 종합 결론

본 비교는 두 차례에 걸쳐 수행했다. **1회차**는 ChatGPT 5.5 · Claude Opus 4.8 · Gemini 3.5 Flash를 동일 조건으로 비교했고, 세 모델이 각각 작성한 비교·선정 보고서까지 다시 교차 검증했다. **2회차**는 비교 공정성 보완을 위해 Gemini를 상위 추론 티어인 3.1 Pro로 추가 재테스트했다(\$10). 두 차례 검토 결과, **최종 적용 모델은 Claude Opus 4.8로 유지한다**.

세 모델이 작성한 분석 보고서가 **독립적으로 모두 Claude를 1위로 지목**했다는 점이 이 결론의 객관성을 담보하는 핵심 근거다. 평가자이자 평가 대상인 이해충돌 구조에서도 결론이 한 방향으로 수렴했다(수렴 타당도). 오류 심각도를 기준으로 재조정 한 회차 통합 점수는 **Claude 4.77 > ChatGPT 4.32 > Gemini 3.82**이며, 2회차에서 Gemini를 3.1 Pro로 올리자 평균이 ≈ 4.1 로 상승해 ChatGPT와의 격차는 좁혀졌으나 순위는 그대로 유지됐다.

본 과업의 핵심 변수는 문장 품질이 아니라 **결정/제안/의견/사실을 섞지 않고 분리하는 능력**이었고, 이 축에서 Claude가 가장 안정적이었다.

2. 평가 환경 (재현성 메타데이터)

항목	ChatGPT	Claude	Gemini
모델명/버전	ChatGPT 5.5	Claude Opus 4.8	Gemini 3.5 Flash
사용 채널	웹	웹	웹
사용 날짜	2026-06-08	2026-06-08	2026-06-08
요금제(무료/유료)	유료	유료	유료
주요 설정	기본값	기본값	기본값

- 제어 조건:** 세 모델 모두 유료 요금제의 웹 인터페이스에서, 다른 프로젝트 맥락이 없는 독립된 새 대화창에 동일 프롬프트·동일 회의 메모를 입력했으며, 평가는 각 모델의 출력물(최초 응답)을 기준으로 했다.
- 2회차 보완:** 위 표는 1회차(Gemini 3.5 Flash) 기준이며, 2회차에서 Gemini를 상위 티어 **3.1 Pro**로 교체해 동일 조건에서 재테스트했다(\$10).

3. 평가 기준 (6개 공통 축)

사전에 확정된 6개 축으로만 정량 평가했다. 문장의 심미성보다 **사내에 즉시 공유 가능한 실무적 안정성**에 무게중심을 둔다.

평가 항목	보는 기준
정확성	회의 메모의 내용을 빠뜨리거나 왜곡하지 않았는가

평가 항목	보는 기준
형식 준수	요청한 7개 항목과 Markdown 표 형식을 지켰는가
Action Items 품질	담당 역할·작업·기한을 실무적으로 잘 나눴는가
확인 필요 항목 분리	미정/보류/추가 검토 사항을 잘 분리했는가
환각 억제	회의록에 없는 내용을 확정처럼 쓰지 않았는가
실무 활용성	실제 사내 공유용 회의록으로 바로 쓸 수 있는가

4. 최종 통합 점수표 (5점 만점)

세 분석 보고서의 점수를 단순 평균하지 않고, **반복적으로 지적된 오류의 심각도를 기준으로 재조정**한 값이다.

평가 항목	ChatGPT 5.5	Claude Opus 4.8	Gemini 3.5 Flash
정확성	4.2	4.8	3.6
형식 준수	4.8	4.7	4.7
Action Items 품질	4.1	4.8	3.5
확인 필요 항목 분리	4.4	4.8	3.8
환각 억제	4.1	4.8	3.5
실무 활용성	4.3	4.7	3.8
평균	4.32	4.77	3.82

종합 순위: Claude Opus 4.8 (4.77) > ChatGPT 5.5 (4.32) > Gemini 3.5 Flash (3.82)

5. 모델별 통합 평가 (점수 근거)

Claude Opus 4.8 — 최종 선정

세 보고서 모두 1위로 평가했다. 가장 큰 강점은 회의록에서 확정된 내용과 미확정 내용을 구분하는 능력이다.

- **사실/추론 분리:** 가능한 리스크 항목 전면에 "회의 메모에 명시된 사실에서 파생되는 추론이며 확정 사항이 아님"을 명시해 환각을 차단했다.
- **의견/제안의 결정화 방지:** 퍼블리싱 담당의 "반응형+모바일 우선"을 결정사항으로 단정하지 않고 작업 의견으로 분리했고, 인증서 관리 기능은 "PM 제안 + 클라이언트 회신 대기"로 표기했다.
- **Action Items 의존성 보존:** 기한이 없는 작업에 "확인 필요"만 채우지 않고 "사이트맵 확정 후", "디자인 확정 후"처럼 업무 선후관계를 함께 표기했으며, 개발 담당 작업 2건을 모두 포함했다.
- **아쉬운 점:** 보고체("~함") 위주로 다소 경직되고, 요청 외 헤더 블록·인용구·이모지를 추가해 형식 준수에서 미세 감점(4.7).

ChatGPT 5.5 — 실용적 대안 (2위)

문서 구조화와 한국어 표현이 가장 안정적이다.

- **장점:** 7개 항목을 모두 충실히 반영했고, 지시에 없던 후속 일정 섹션을 '일정-내용' 표로 자발적으로 재구성해 가독성을 높였다.
- **아쉬운 점:** 원문에서 "이메일 발송 기능은 기본 범위에 포함 가능"이라는 개발 담당의 **설명**을, 확정된 실행 항목 ("개발 담당 - 이메일 발송 기능 구현")으로 임의 배정한 과잉 추론 오류가 있었다. 또한 확인 필요 섹션과 하단 모음의 내용이 거의 동일하게 중복된다.

Gemini 3.5 Flash — 경량 모델의 한계 (3위)

전체 구조와 형식 준수는 충족했고, 하단 모음을 [일정/기한]·[데이터] 등 카테고리 태그로 분류해 시각적 가독성은 가장 높았다.

- **핵심 감점 1 (Action 누락):** 회의 메모에 개발 범위 논의가 있었음에도, Action Items 표에서 **개발 담당 행 자체**가 통째로 누락되어 후속 업무 추적이 불가능한 결함이 발생했다.
- **핵심 감점 2 (왜곡):** 퍼블리싱 담당의 **의견** ("반응형 기준으로 작업하되 모바일 화면을 우선 고려")과 클라이언트 회신 대기 중인 **제안** ("인증서 파일 관리 기능을 추가 견적 대상으로 분리")을 공식 결정사항처럼 단정적으로 분류했다. 둘 다 회의에서 확정된 사항이 아니므로(의견·미확정 제안), 정확성·환각 억제 양쪽에서 감점 요인이다.
- 리스크 항목에 "추론이며 확정 아님"이라는 안전장치를 명시하지 않은 점도 차이를 만들었다.

6. 한국어 자연스러움 (보조 관찰 항목)

한국어 자연스러움은 사전 확정된 6개 공통 평가축에 포함되지 않아 정량 점수에서 제외했다. 다만 사내 공유 문서 특성상 보조적으로 검토했으며, ChatGPT가 가장 정중·자연스러운 문체, Claude는 분리 정확도는 최상이나 보고체가 다소 경직, Gemini는 간결하나 실무 판단의 세밀함이 부족했다.

본 항목을 정량 점수에서 제외한 이유: 평가 축은 사후에 임의로 추가된 것이 아니라 사전에 확정된 것이어야 근거로서 방어 가능하다. 특정 모델에 유리한 축이 뒤늦게 끼워졌다는 의심을 차단하기 위해 보조 관찰로만 다룬다.

7. 3개 분석 보고서 자체에 대한 메타 평가

각 모델이 작성한 **분석 보고서**의 신뢰도는, 자기 자신을 어떻게 채점했는지(자기평가 편향)를 기준으로 검증했다.

검증 항목	ChatGPT 분석	Claude 분석	Gemini 분석
최종 선정	Claude (일치)	Claude (일치)	Claude (일치)
자기평가 정직성	자기 2위 유지	자기 우승이나 만점 회피·자기 감점	단독본 자기 격상 → 통합본서 자진 하향
점수 변별력	좁음(관대)	넓음(엄격)	단독본 압축 → 통합본 보정
종합 신뢰도	높음	매우 높음	보통 → 통합 단계서 개선

- **수렴 검증:** 독립된 세 평가자가 모두 Claude를 1위로 지목 → "Claude가 Claude를 띄운 것"이 아니라 객관적으로 검증된 결론이다.

- **자기평가 편향:** Gemini 단독 보고서는 자기를 2위로 올리고 자신이 실패한 '환각 억제' 축에 만점을 부여했으나, 세 보고서를 함께 본 통합 단계에서는 자기 점수를 합의값으로 자진 하향했다 — 편향이 교정 가능함을 보여준다. 반대로 ChatGPT는 단독 보고서에서는 정직했으나 최종 6축 표에서 관대한 원점수로 회귀했다.
- **방법론 원칙:** 따라서 통합 점수는 개별 보고서 점수를 그대로 평균하지 않고, 반복 지적된 오류 근거를 기준으로 재조정된 값(4장)을 채택했다.

8. 최종 선정 결론 및 근거

최종 적용 모델: Claude Opus 4.8

사내 공유용 회의록은 '보기 좋은 형식'보다 '**왜곡 제로(0)의 신뢰성**'이 절대적으로 우선한다. Claude는 형식 준수에서 일부 감점(주석·이미지 과다)이 있었으나, 이는 사실 관계를 안전하게 방어하는 과정에서 발생한 트레이드오프다. 선정 근거는 다음 네 가지다.

1. **사실과 추론의 구분** — 가능한 리스크를 확정사항이 아닌 추론으로 명시하고, 메모에 없는 내용을 과도하게 확정하지 않았다.
2. **의견과 결정사항의 분리** — 퍼블리싱 담당의 의견을 결정사항으로 올리지 않고 공식 확정 여부를 확인할 항목으로 처리했다.
3. **Action Items 실무 완성도** — 기한 미정 작업에 업무 간 의존관계를 함께 표기하고 개발 작업 2건을 모두 포함했다.
4. **확인 필요 항목의 세밀함** — 인증서 포함 여부, 추가 견적, 게시판 데이터, 다국어, 관리자·호스팅 정보, 디자인·퍼블리싱 기한, 개발 일정까지 폭넓게 분리했다.

보조 결론: 신속하고 정중한 톤의 가벼운 공유가 목적이면 ChatGPT 5.5가 좋은 대안이다(단, 공유 전 Action Item의 확정 여부 검토 필요). Gemini 3.5 Flash는 누락된 개발 Action 보완·결정사항 재분류 등 사람의 개입 리스크가 커 단독 자동화 파이프라인에는 부적합하다.

일반화 제한: 본 비교는 하나의 가상 회의록 샘플과 동일 프롬프트를 기준으로 수행했다. 따라서 모든 업무 과업에서 Claude Opus 4.8이 항상 우수하다고 일반화할 수는 없다. 다만 이번 회의록 요약 및 Action Items 정리 과업에서는 사실·추론 구분, 미확정 사항 처리, Action Items 품질 측면에서 가장 안정적인 결과를 보였다.

9. 한계 및 v2 프롬프트 개선 방향

- **분석의 한계:** 단일 회의록 샘플·단일 프롬프트 기반이며, 1회차는 모델 티어(상위 추론 티어 vs 속도 최적화 경량 티어)를 통제하지 않았다. 점수는 모델 계열의 절대 우열이 아니라 "동일 과업·동일 입력 조건에서의 출력 품질 비교"로 한정해 해석해야 한다. (모델 티어 한계는 §10 2회차 보완에서 Gemini 3.1 Pro 재테스트로 보완·확인했다.)
- **후속 검증 제한:** 짧은/긴/정보 부족 회의록으로 샘플 다양화, 피드백 후 개선력 비교, 사람의 최종 수정 소요 시간 측정, 실제 PM·기획자 관점의 만족도 평가.

v2 시스템 프롬프트 가이드라인 (자가 검증 루프)

세 모델의 공통 감점 패턴이 ① 담당 역할 누락 ② 의견·제안의 결정사항 오분류에 집중되었으므로, 시스템 프롬프트에 다음 두 가이드라인을 추가해 v2로 고도화하고 재테스트한다.

...

- (a) 역할 누락 방지: "최종 출력 직전, 원문 메모에 등장한 모든 담당 역할(클라이언트·PM·기획·디자인·퍼블리싱·개발)이 Action Items 표에 최소 1행 이상 포함됐는지 자체 검증하고, 누락 시 강제로 행을 추가해 매핑하라."
- (b) 사실/의견 분리: "회의 중 합의가 끝난 것만 결정사항에 넣고, 개인 의견이나 클라이언트 회신 대기 중인 제안 상태의 내용은 결정사항으로 단정하지 말고 '확인 필요 사항' 또는 '주석'으로 격리하라."
- ...

10. 2회차 보완 — Gemini 3.1 Pro 재테스트

배경

1회차 비교는 Gemini만 속도 최적화 경량 티어(3.5 Flash)를 사용해 모델 등급이 어긋난 한계가 있었다(\$9). 이를 보완하기 위해 Gemini를 상위 추론 티어인 **3.1 Pro**로 교체해, 동일 프롬프트·동일 회의 메모·동일 6개 평가 축으로 새 대화창(유료·웹)에서 재테스트했다. ChatGPT·Claude는 출력물이 1회차와 동일하므로 점수를 유지하고, **Gemini 열만 갱신한다.**

재테스트 점수표 (5점 만점)

평가 항목	ChatGPT 5.5	Claude Opus 4.8	Gemini 3.1 Pro	Gemini 3.5 Flash (1회차)
정확성	4.2	4.8	4.0	3.6
형식 준수	4.8	4.7	4.8	4.7
Action Items 품질	4.1	4.8	4.0	3.5
확인 필요 항목 분리	4.4	4.8	4.0	3.8
환각 억제	4.1	4.8	3.5	3.5
실무 활용성	4.3	4.7	4.0	3.8
평균	4.32	4.77	4.1	3.82

순위: Claude Opus 4.8 (4.77) > ChatGPT 5.5 (4.32) > Gemini 3.1 Pro (≈4.1)

항목별 판단 (Gemini 3.1 Pro — 실제 출력 기준)

- **정확성 4.0** — 핵심 사실은 정확하나, 퍼블리싱 담당의 **의견**("반응형 기준 + 모바일 우선")과 제품 정보 수정·문의 품 이메일 발송(제안·"포함 가능" 단계)을 "결정사항"으로 단정함. 다만 인증서 관리 기능의 미확정 상태는 정확히 분리.
- **형식 준수 4.8** — 7개 항목 + "확인 필요 항목 모음" ((요약) 라벨)을 모두 정확히 충족하고 Markdown 표·역할 명 처리도 준수. 요청하지 않은 별도 섹션은 없음(앞선 "추가 요약 섹션" 지적은 요청된 모음을 오인한 것으로 정정).
- **Action Items 품질 4.0** — Flash가 통째로 누락했던 **개발 담당 행을 포함**해 7개 역할을 모두 표기했고, "사이트 맵 확정 후"·"디자인 확정 후" 선후관계도 작업란에 보존. 단 개발 작업이 "기능 범위·일정 최종 산정 및 개발 진행"으로 포괄적이어서 제품 정보 수정·이메일 발송이 구체적으로 명시되지는 않음.

- **확인 필요 항목 분리 4.0** — 인증서 관리 기능·게시판 데이터·다국어·관리자/호스팅 정보를 '확인 필요 사항'에 정확히 분리(Flash 대비 인증서 처리 개선), 모음에도 역할·기한을 함께 표기. 결정사항과의 직접 중복은 없음.
- **환각 억제 3.5** — 위 정확성과 같은 이유로 감점. 퍼블리싱 의견·제안 단계 항목을 결정사항으로 단정했고, '가능한 리스크'에 "추론이며 확정 아님"이라는 안전장치를 명시하지 않음.
- **실무 활용성 4.0** — 역할별 추적이 가능한 초안이나, 결정사항으로 단정된 의견·제안 항목은 공유 전 PM이 "실제 확정 여부"를 한 번 검토해야 함.

결론

Gemini 3.1 Pro는 3.5 Flash 대비 **정확성(3.6→4.0)·Action Items(3.5→4.0)·형식 준수(4.7→4.8)·확인 필요 분리(3.8→4.0)에서 고르게 개선**됐다. 특히 Flash가 통째로 누락했던 개발 담당 Action을 포함했고, 인증서 미확정 상태도 확인 필요로 정확히 분리했다. 그러나 **환각 억제(3.5)만은 변하지 않았는데**, 퍼블리싱 담당의 의견과 제안 ·"포함 가능" 단계 항목을 여전히 결정사항으로 단정했기 때문이다. 이 축은 Claude(4.8)와 가장 큰 격차를 보인 지점으로, 이번 과업·입력 조건에서는 티어를 올려도 "의견·제안을 확정처럼 분류하는 경향"이 해소되지 않았다(단일 재테스트 결과이므로 Gemini 계열 전반으로 일반화하지는 않는다).

티어를 통제한 재테스트에서도 **순위(Claude > ChatGPT > Gemini)가 유지**되었으므로, 1회차의 티어 미통제 한계가 결론을 왜곡한 것이 아님이 확인됐다. Gemini 3.1 Pro는 Flash 대비 평균이 3.82에서 ≈4.1로 올라 ChatGPT(4.32)와의 격차는 좁혀졌으나, 최종 적용 모델은 **Claude Opus 4.8 유지**이며 그 선정의 강건성이 오히려 강화됐다.

본 보고서의 채점은 원본 회의 메모, 세 모델의 출력물, 세 모델이 작성한 분석 보고서를 항목별로 교차 대조하여 작성되었으며, 모든 감점·가점 사유는 실제 출력 문구로 검증 가능하다.

부록 A. 공통 프롬프트 전문 (3개 모델 동일 입력)

세 모델에 동일하게 입력한 프롬프트 전문이다. 재현용 별도 파일은 `evidence/공통프롬프트.md` 참조.

페르소나 / 지시

너는 웨이전시 프로젝트 매니저 출신의 프로젝트 문서화 전문가다. 아래 회의 메모를 읽고 사내 공유용 회의록으로 정리해줘.

출력 항목 및 작성 규칙

...

하기 회의 메모 사내 공유용 회의록으로 정리요청 함.

출력 항목:

1. 회의 목적
2. 결정사항
3. Action Items
4. 확인된 사실
5. 가능한 리스크
6. 확인 필요 사항
7. 후속 일정

작성 규칙:

- 회의 메모에 없는 내용은 확정적으로 말하지 않는다.
- 추론이 필요한 내용은 “가능한 리스크”로 분리한다.
- 정보가 부족한 항목은 “확인 필요”로 표시한다.
- 인물 실명은 사용하지 말고 역할명으로 바꾼다.
- Action Items는 담당 역할, 작업, 기한을 표로 정리한다.
- 기한이 없으면 “확인 필요”라고 표시한다.
- 최종 결과는 Markdown 형식으로 작성한다.
- 마지막에 “확인 필요 항목”을 따로 모아준다.

...

부록 B. 가상 회의록 입력 데이터 전문 (테스트 케이스)

세 모델에 공통 입력한 회의 메모 원문이다(가상 시나리오 · 실명 미포함). 재현용 별도 파일은 `evidence/가상회의록_입력데이터.md` 참조.

[회의 메모] 회의 주제: B2B 제조기업 홈페이지 리뉴얼 프로젝트 Kick-off 회의 참석 역할: - 클라이언트 담당자 - 프로젝트 매니저

- 기획 담당 - 디자인 담당 - 퍼블리싱 담당 - 개발 담당 회의 내용: - 클라이언트는 기존 홈페이지가 오래되어 모바일 화면에서 가독성이 떨어지고, 제품 문의 전환율이 낮다는 문제를 제기했다. - 이번 리뉴얼의 1차 목표는 회사 신뢰도 개선, 제품 정보 탐색 편의성 향상, 문의 접수 증가로 정리했다. - 홈페이지 주요 메뉴는 회사소개, 제품소개, 기술자료, 납품사례, 고객센터로 구성하기로 했다. - 제품소개 페이지는 제품군별 목록, 상세페이지, 인증서 다운로드 영역을 포함해야 한다. - 고객센터 페이지에는 이름, 연락처, 이메일, 문의 제품군, 문의 내용을 입력받는 폼이 필요하다. - 클라이언트는 관리자 페이지에서 제품 정보를 직접 수정하고 싶다고 요청했다. - 개발 담당은 제품 정보 관리 기능은 가능하지만, 인증서 파일 업로드 관리까지 포함하면 개발 범위와 일정이 늘어날 수 있다고 설명했다. - 프로젝트 매니저는 우선 1차 범위에는 제품 정보 수정 기능만 포함하고, 인증서 파일 관리 기능은 추가 견적 대상으로 분리하자고 제안했다. - 클라이언트 담당자는 내부 검토 후 인증서 관리 기능 포함 여부를 이번 주 금요일까지 회신하기로 했다. - 기획 담당은 다음 주 화요일까지 사이트맵과 주요 화면 구성안을 작성하기로 했다. - 디자인 담당은 사이트맵 확정 후 메인 시안 1안을 제작하기로 했다. - 퍼블리싱 담당은 디자인 확정 후 반응형 기준으로 작업하되, 모바일 화면을 우선 고려해야 한다고 의견을 냈다. - 개발 담당은 문의 폼 접수 내역을 이메일로 발송하는 기능은 기본 범위에 포함 가능하다고 설명했다. - 클라이언트는 기존 홈페이지의 게시판 데이터 이전 여부도 문의했지만, 현재 게시판 데이터 양과 구조를 확인하지 못해 즉시 확정하지 못했다. - 프로젝트 매니저는 기존 홈페이지 관리자 접속 정보와 호스팅 정보를 클라이언트에게 요청하기로 했다. - 클라이언트 담당자는 회사 로고 원본 파일, 제품 카탈로그, 인증서 PDF, 납품사례 자료를 다음 주 월요일까지 전달하기로 했다. - 전체 오픈 목표일은 다음 달 말로 논의되었지만, 최종 일정은 자료 전달일과 추가 기능 범위 확정 후 다시 산정하기로 했다. - 회의 말미에 다국어 페이지가 필요할 수 있다는 의견이 나왔지만, 이번 회의에서는 구체적인 언어 범위와 번역 방식은 정하지 않았다. - 다음 회의는 사이트맵 초안이 나온 뒤 진행하기로 했다.

부록 C. 원본 입력·출력 파일 (재현성)

원본 입력과 모델별 출력물 전문은 가독성을 위해 본문에 덤프하지 않고 별도 파일로 보존했다(미션 제약사항: 원본 로그 전문은 별도 파일로 재현 가능하게). 저장소 구조는 다음과 같다.

`evidence/` — 입력·출력 근거

- `evidence/공통프롬프트.md` — 세 모델 동일 입력 프롬프트
- `evidence/가상회의록_입력데이터.md` — 공통 입력 회의 메모 원문
- `evidence/chatgpt_result.md` — ChatGPT 5.5 출력물

- evidence/claude_result.md — Claude Opus 4.8 출력물
- evidence/gemini_result.md — Gemini 3.5 Flash 출력물 (1회차)
- evidence/gemini_result_3.1pro.md — Gemini 3.1 Pro 출력물 (2회차 재테스트)

logs/ — 실행 로그 원본 (산출물 #3)

- logs/ — 10턴 이상 대화 로그 전문

평가는 각 모델의 최초 응답을 기준으로 했으며, 위 파일을 통해 동일 입력 → 동일 출력 재현이 가능하다.