

[종합 통합 보고서] LLM 업무 자동화 프롬프트 패키지

1. 보고서 개요

본 보고서는 동일한 업무 과업 프롬프트를 3종의 최신 대규모 언어 모델(LLM)에 입력하고, 각 결과물을 정량적·정성적 기준에 따라 비교 분석하여 실무 적용에 가장 적합한 최적의 모델을 선정하기 위해 작성되었습니다.

비교 대상 과업은 'B2B 제조기업 홈페이지 리뉴얼 프로젝트 킥오프 회의록 정리'입니다. 본 과업은 단순한 분량 축소가 아니라, 다중 제약 조건을 준수하면서 회의 메모 속 사실(Fact)을 왜곡 없이 결정사항, Action Items, 가능한 리스크, 확인 필요 사항 등으로 정교하게 분리·구조화하는 능력을 중점적으로 평가했습니다.

2. 평가 환경 및 대상 모델

비교의 공정성을 위해 세 모델 모두 다른 프로젝트 맥락이 없는 독립된 새 대화창에서 테스트를 진행했습니다.

- 테스트 일자: 2026-06-08
- 제어 조건: 동일 프롬프트 및 동일 회의 메모 입력, 최초 응답 기준 평가

구분	모델명 / 버전	사용 채널	비고
ChatGPT	GPT-5.5	Web UI	프로젝트 맥락이 없는 새 대화창 테스트
Claude	Claude Opus 4.8	Web UI	동일 프롬프트 및 제약 조건 입력
Gemini	Gemini 3.5 Flash	Web UI	동일 프롬프트 및 제약 조건 입력

3. 평가 기준 및 배점 안내

각 모델은 5.0점 만점을 기준으로 평가되었으며, 문장의 심미성보다는 실제 사내외에 즉시 공유할 수 있는지에 대한 '실무적 안정성'과 '정확성'에 무게중심을 두었습니다.

평가 항목	세부 평가 기준
정확성	회의 메모의 내용을 왜곡하거나 과도하게 해석하지 않았는가
형식 준수	요청한 7개 필수 항목 목차와 Markdown 표 형식을 지켰는가
Action Items 품질	담당 역할, 구체적 작업, 기한 간의 인과관계를 실무적으로 분리했는가
확인 필요 항목 분리	미정, 보류, 추가 검토 사항을 명확히 분리했는가

평가 항목	세부 평가 기준
환각 억제	회의록에 없는 내용을 확정된 사실처럼 작성하지 않았는가
실무 활용성	인간의 추가 편집 없이 실제 회의록 초안으로 바로 활용 가능한가

4. 모델별 평가 결과 총괄표

평가 항목	ChatGPT 5.5	Claude Opus 4.8	Gemini 3.5 Flash
1. 정확성	4.4	4.8	4.0
2. 형식 준수	4.8	5.0	4.5
3. Action Items 품질	4.2	4.7	3.8
4. 확인 필요 항목 분리	4.5	4.9	4.0
5. 환각 억제	4.2	4.8	3.7
6. 실무 활용성	4.4	4.8	4.0
종합 평균 점수	4.4	4.8	4.0

※ 종합 순위: Claude Opus 4.8 (4.8) > ChatGPT 5.5 (4.4) > Gemini 3.5 Flash (4.0)

5. 모델별 정성 평가 분석

① Claude Opus 4.8 (종합 평균: 4.8) — 🏆 최종 선정 모델

"사실과 추론의 경계를 명확히 구분하여 실무적 리스크를 최소화한 최고의 아웃풋"

- **의존성(Dependency) 보존:** 기한이 없는 Action Item에 대해 기계적으로 '확인 필요'만 적지 않고, "사이트맵 확정 후 (구체 기한 확인 필요)"와 같이 업무 흐름의 선행 조건을 유기적으로 매핑했습니다.
- **사실과 의견의 엄격한 분리:** 퍼블리싱 담당자의 개인 발언을 결정사항으로 단정 짓지 않고, "회의 중 제시된 작업 의견으로 공식 확정은 아님"이라는 참고 주석을 분리해 냈습니다.
- **안전장치(Guardrail) 장착:** 가능한 리스크 항목 전면에 "명시된 사실에서 파생되는 추론이며 확정 사항이 아님"이라는 문구를 스스로 배치해 환각 위험을 통제했습니다.

아쉬운 점: 문체 중심이 '~함' 형태의 보고체 위주여서 다소 딱딱하게 느껴질 수 있으며, 요청 외의 헤더 블록이나 인용구를 추가하여 '정석적인 지시 준수' 측면에서 미세한 감점 요인이 존재합니다.

② ChatGPT 5.5 (종합 평균: 4.4) — 🏆 실용적 대안

"정밀한 요구사항 분류와 뛰어난 구조화 능력, 다만 과도한 실행 업무 해석은 주의 필요"

- **우수한 구조화 안정성:** 결정사항, 실행 항목, 확인된 사실, 리스크 항목이 직관적으로 분류되어 있어 결과물의 가독성이 높습니다.
- **유연한 마감 능력:** 지시사항에 명시되지 않았음에도 '후속 일정' 섹션을 '일정-내용' 구조의 가독성 높은 표 형태로 스스로 재구성하여 가치를 높였습니다.

아쉬운 점: 원문의 "이메일 발송 기능은 기본 범위에 포함 가능하다"라는 개발 담당의 기능적 설명을 "개발 담당 - 문의 폼 접수 내역 이메일 발송 기능 구현"이라는 확정적 실행 항목으로 임의 배정하는 과도한 추론 오류를 보였습니다. 또한, 섹션 간 텍스트가 다소 중복되어 반복되는 인상을 줍니다.

③ Gemini 3.5 Flash (종합 평균: 4.0) — 🏆 경량화 모델의 한계

- **주요 장점:** 전체 요약이 간결하며, 최하단 확인 필요 항목 모음집을 [일정/기한], [데이터] 등의 카테고리 태그로 분류하여 시각적 인지 독해성을 극대화했습니다.
- **주요 단점:** '개발 담당'의 작업 행 자체가 Action Items 표에서 통째로 누락되는 치명적인 결함이 발견되었습니다. 퍼블리싱 담당자의 의견이나 클라이언트의 제안 내용을 공식 합의된 '결정사항'인 것처럼 단정적으로 분류하여 팩트를 왜곡했습니다.

6. 최종 선정 결론 및 실무 제언

사내 공유용 보고서 및 회의록은 '보기 좋은 형식'보다 '**왜곡 제로(0)의 신뢰성**'이 절대적인 우선순위를 가집니다. Claude Opus 4.8은 사실 관계의 경계를 완벽히 방어하고 프로젝트의 선후 관계를 유일하게 짚어냈다는 점에서, 기업의 의사결정 근거 문서로 즉시 사용하기에 가장 안전하고 적합합니다.

실무적 팁 (보조 결론):

- **ChatGPT 5.5**는 큰 오류 없이 전 항목이 고르게 안정적이어서, 최종 공유 전 Action Item의 확정 여부만 사람이 검토해 준다면 훌륭한 실용적 대안이 될 수 있습니다.
- **Gemini 3.5 Flash**의 경우, 개발 담당 Action Item 보완 및 결정사항 재분류 등 사람이 개입해야 하는 리소스가 크므로 단독 자동화 파이프라인 구축에는 부적합합니다.

7. 한계점 및 v2 프롬프트 개선 방향 (가드레일 전략)

- **분석의 한계:** 본 테스트는 하나의 가상 킥오프 회의록 샘플만을 바탕으로 진행되었으므로 모든 비즈니스 상황에 일반화할 수 없으며, 모델의 체급(플래그십 추론 티어 vs 속도 최적화 경량 티어)을 통제하지 않은 제약이 있습니다.
- **v2 고도화를 위한 시스템 프롬프트 보완 방향:** 세 모델의 공통적인 감점 패턴이 '특정 담당 역할 누락'과 '의견/제안의 결정사항 오분류'에 집중되어 있으므로, 차기 v2 프롬프트에는 아래 두 가지 자가 검증(Self-Correction Loop) 가드레일을 추가할 것을 제안합니다.

[v2 프롬프트 추가 가드레일 예시]

1. 역할 누락 방지: "최종 출력을 생성하기 직전, 내부적으로 원문 메모에 등장한 모든 담당 역할(클라이언트, PM, 기획, 디자인, 퍼블리싱, 개발)이 'Action Items' 표에 최소 1행 이상씩 포함되었는지 자체 검증하고 누락 시 강제 매핑하라."
2. 사실/의견 분리: "회의 중 합의가 완전히 끝난 것만 '결정사항'에 넣고, 특정 담당자의 개인 의견이나 클라이언트 회신 대기 중인 '제안' 상태의 내용은 절대로 결정사항으로 단정하지 말고 '주석'이나 '확인 필요 사항'으로 격리하라."