

LLM 모델 비교·선정 통합 분석 보고서

3개 AI 평가 보고서 종합 및 최종 선정 근거 정리

구분	내용
비교 과업	웹에이전시 B2B 제조기업 홈페이지 리뉴얼 회의록 요약 및 Action Items 정리
비교 모델	ChatGPT 5.5 / Claude Opus 4.8 / Gemini 3.5 Flash
종합 대상	각 모델이 작성한 모델 비교·선정 보고서 3건
통합 결론	Claude Opus 4.8 최종 선정
작성일	2026-06-08

본 문서는 3개 AI가 각각 작성한 모델 비교·선정 보고서를 재검토하여, 보고서 자체의 객관성·일관성·편향 가능성과 모델별 출력 품질을 함께 평가한 통합 분석본입니다. 최종 점수는 단순 평균이 아니라 반복적으로 지적된 오류의 실무적 심각도를 기준으로 재조정했습니다.

1. 종합 결론

3개 보고서는 모두 최종 선정 모델을 Claude Opus 4.8로 제시했습니다. 점수 폭과 표현 강도에는 차이가 있었지만, 회의록 요약 및 Action Items 정리 업무에서 Claude가 가장 안정적이라는 결론은 일치했습니다.

다만 최종 평가는 ‘어떤 모델이 더 보기 좋은 문서를 만들었는가’보다 ‘결정사항·의견·추론·확인 필요 사항을 얼마나 안전하게 구분했는가’를 중심으로 판단했습니다. 회의록은 실제 업무 실행과 의사결정의 근거가 될 수 있으므로, 문장 자연스러움보다 사실관계의 안정성이 더 중요합니다.

모델	3개 보고서의 공통 판단	통합 결론
Claude Opus 4.8	모든 보고서에서 1위	최종 선정 모델
ChatGPT 5.5	대체로 2위. 구조화와 문장 품질은 우수	실용적 대안
Gemini 3.5 Flash	독립 평가 2건에서 3위. 자기 보고서만 상대적으로 높게 평가	초안용은 가능하나 단독 사용 전 검토 필요

2. 3개 보고서 자체에 대한 메타 평가

이번 분석에서는 모델 출력 결과뿐 아니라, 각 AI가 작성한 ‘평가 보고서’의 품질도 함께 검토했습니다. 특히 평가자가 평가 대상이기도 하므로, 자기 모델을 어떻게 채점했는지 객관성을 판단하는 중요한 기준이 되었습니다.

보고서	강점	한계	신뢰도 판단
ChatGPT 분석	평가 축과 한계 설명이 균형적이며, 자기 모델의 약점도 비교적 정직하게 지적했습니다.	점수 폭이 좁아 모델 간 격차가 다소 완만하게 보입니다.	높음
Claude 분석	감점 기준이 가장 실무적입니다. 의견·제안의 결정화, 개발 Action 누락 등 핵심 오류를 정확히 짚었습니다.	Gemini 감점이 다소 강하고, 문서가 압축적입니다.	매우 높음
Gemini 분석	구조가 간결하고 빠르게 읽기 좋습니다.	자기 모델에 상대적으로 후합니다. 특히 환각 억제 만점은 실제 오류와 맞지 않습니다.	보통

핵심 발견: 자기평가 편향

Gemini 분석 보고서는 Gemini 3.5 Flash를 상대적으로 높게 평가했지만, 다른 두 보고서는 Gemini의 주요 오류를 더 무겁게 보았습니다. 특히 Gemini 원출력에는 퍼블리싱 담당자의 의견을 결정사항처럼 처리한 문제와 개발 담당 Action Item 누락이 있었는데, Gemini 분석 보고서는 환각 억제 항목에 높은 점수를 부여했습니다. 따라서 최종 통합 평가는 자기평가 점수를 그대로 평균하지 않고, 반복적으로 지적된 오류를 중심으로 재조정했습니다.

3. 최종 평가축 정리

최종 통합 점수표에서는 6개 공통 평가축만 사용했습니다. ‘한국어 자연스러움’은 ChatGPT 분석 보고서에서 추가된 보조 관찰 항목이지만, Claude와 Gemini 분석 보고서의 공통 평가축에는 없었으므로 최종 정량 점수에서는 제외했습니다.

평가 항목	평가 기준
정확성	회의 메모의 내용을 왜곡하거나 과도하게 해석하지 않았는가
형식 준수	요청한 7개 항목과 Markdown 표 형식을 충실히 지켰는가
Action Items 품질	담당 역할, 작업, 기한 및 선후관계를 실무적으로 분리했는가
확인 필요 항목 분리	미정, 보류, 추가 검토 사항을 명확히 분리했는가
환각 억제	회의록에 없는 내용을 확정된 사실처럼 작성하지 않았는가

평가 항목	평가 기준
실무 활용성	실제 사내 공유용 회의록 초안으로 바로 활용 가능한가

보조 관찰 항목: 한국어 자연스러움

한국어 자연스러움은 정량 점수에 반영하지 않았지만, 사내 공유 문서라는 특성상 보조적으로 검토했습니다. ChatGPT는 가장 자연스럽고 정중한 문체를 보였고, Claude는 내용 분리는 가장 안정적이지만 보고체가 다소 딱딱했습니다. Gemini는 간결하고 읽기 쉬웠지만 실무 판단의 세밀함이 부족했습니다.

4. 통합 점수표

평가 항목	ChatGPT 5.5	Claude Opus 4.8	Gemini 3.5 Flash
정확성	4.2	4.8	3.6
형식 준수	4.8	4.7	4.7
Action Items 품질	4.1	4.8	3.5
확인 필요 항목 분리	4.4	4.8	3.8
환각 억제	4.1	4.8	3.5
실무 활용성	4.3	4.7	3.8
평균	4.32	4.77	3.82

점수 해석: Claude는 만점으로 처리하지 않았습니다. 일부 주석과 보조 설명이 많아 빠른 공유용 문서로는 다소 무거울 수 있고, 일부 표현은 강하게 읽힐 여지가 있기 때문입니다. 그럼에도 핵심 평가축인 사실·추론 구분, 의견·결정사항 분리, Action Items 품질에서 가장 안정적이었습니다.

5. 모델별 통합 평가

5-1. Claude Opus 4.8 - 최종 선정 모델

Claude Opus 4.8은 세 보고서 모두에서 최종 선정 모델로 평가되었습니다. 가장 큰 장점은 회의록에서 확정된 내용과 아직 확정되지 않은 내용을 조심스럽게 구분한 점입니다.

주요 강점

- 인증서 파일 관리 기능을 기본 범위로 확정하지 않고, 추가 건적 대상이면서 클라이언트 회신 대기 상태라는 점을 함께 표시했습니다.
- 퍼블리싱 담당자의 ‘반응형 + 모바일 우선’ 의견을 결정사항으로 단정하지 않고, 회의 중 제시된 작업 의견으로 분리했습니다.
- 디자인 작업은 ‘사이트맵 확정 후’, 퍼블리싱 작업은 ‘디자인 확정 후’처럼 업무 선후관계를 보존했습니다.
- 가능한 리스크를 확정사항이 아닌 추론으로 명시해 환각 가능성을 가장 잘 억제했습니다.

감점 요소

일부 주석과 보조 설명이 많아 빠른 공유용 문서로는 다소 무거울 수 있습니다. 또한 ‘1차 범위 합의’와 같은 표현은 일부 기능이 회신 대기 상태라는 점을 고려하면 약간 강하게 읽힐 여지가 있습니다.

5-2. ChatGPT 5.5 - 실용적 대안

ChatGPT 5.5는 문서 구조화, 한국어 표현, 전체 항목 총족 측면에서 안정적인 2위로 평가됩니다. 요청한 항목을 빠짐없이 구성했고, Action Items와 후속 일정을 표로 정리해 가독성이 좋았습니다.

주요 강점

- 회의 목적, 결정사항, Action Items, 확인된 사실, 가능한 리스크, 확인 필요 사항, 후속 일정을 안정적으로 구성했습니다.
- ‘논의했습니다’, ‘정리했습니다’, ‘포함 가능합니다’처럼 사내 공유용 문체가 자연스럽습니다.
- 확인 필요 사항을 풍부하게 분리해 프로젝트 체크리스트로 활용하기 좋습니다.

감점 요소

가장 큰 문제는 일부 기능 설명을 실제 Action Item처럼 정리한 점입니다. 예를 들어 ‘문의 폼 접수 내역 이메일 발송 기능은 기본 범위에 포함 가능하다’는 설명을 개발 담당의 실행 업무처럼 배정했습니다. 또한 확인 필요 섹션과 마지막 모음 항목이 중복되어 문서가 반복적으로 보입니다.

5-3. Gemini 3.5 Flash - 초안용은 가능하나 검토 필요

Gemini 3.5 Flash는 전체 구조와 형식 준수는 양호합니다. 다만 실무 회의록 기준으로는 확정사항과 의견성 내용을 구분하는 세밀함이 부족했습니다.

주요 강점

- 요청한 7개 항목을 대체로 포함했고, Action Items도 표 형태로 정리했습니다.
- 확인 필요 항목을 일정, 데이터, 기능 범위 등으로 카테고리화해 빠르게 읽기 좋았습니다.
- 간결한 브리핑용 초안으로는 활용 가능성이 있습니다.

감점 요소

퍼블리싱 담당자의 의견을 결정사항으로 분류한 점이 가장 큰 감점 요소입니다. 또한 개발 담당 Action Item이 누락되어 후속 업무 추적에 문제가 생길 수 있습니다. 인증서 관리 기능도 제안·회신 대기 상태를 더 조심스럽게 처리했어야 합니다.

6. 최종 선정 모델 및 선정 근거

최종 선정 모델은 Claude Opus 4.8입니다.

이번 과업은 단순 요약이 아니라 회의 메모를 기반으로 업무 실행 가능한 회의록을 만드는 작업입니다. 따라서 핵심 판단 기준은 문장 미려함이 아니라, 결정사항과 의견, 사실과 추론, 실행 항목과 확인 필요 사항을 얼마나 안전하게 분리하는가였습니다.

선정 근거	내용
사실·추론 구분	가능한 리스크를 확정사항이 아닌 추론으로 명시했습니다.
의견·결정사항 분리	퍼블리싱 담당자의 의견을 결정사항으로 올리지 않고 확인 필요 성격으로 처리했습니다.
Action Items 품질	업무 선후관계와 조건부 기한을 함께 보존했습니다.
확인 필요 항목	인증서 관리, 게시판 데이터, 다국어, 일정, 개발 범위 등을 세밀하게 분리했습니다.

따라서 이번 ‘회의록 요약 및 Action Items 정리 자동화’ 과업에서는 Claude Opus 4.8이 가장 객관적으로 적합합니다. 다만 이는 모든 업무에서 Claude가 항상 우수하다는 의미가 아니라, 본 샘플과 본 프롬프트 조건에서 가장 안정적인 결과를 보였다는 의미입니다.

7. v2 프롬프트 개선 방향

세 모델의 주요 감점 패턴은 크게 두 가지였습니다. 첫째, 의견·제안이 결정사항으로 처리되는 문제입니다. 둘째, 원문에 등장한 실행 책임이 Action Items에서 누락되는 문제입니다. 이를 막기 위해 v2 프롬프트에는 다음 가드레일을 추가하는 것이 좋습니다.

가드레일	개선 문구
결정사항 분류	회의에서 명시적으로 합의된 내용만 결정사항에 포함한다. 특정 참석자의 의견, 제안, 가능성, 회신 대기 항목은 결정사항으로 단정하지 않는다.

가드레일	개선 문구
Action Items 누락 방지	원문에서 작업, 요청, 검토, 회신, 자료 전달, 일정 확인 등의 책임이 부여된 역할이 Action Items 또는 확인 필요 사항에 빠짐없이 반영되었는지 최종 출력 전 점검한다.
추론 표시	가능한 리스크는 회의 메모에 근거한 추론임을 명시하고, 확정된 사실처럼 표현하지 않는다.
중복 제거	확인 필요 사항과 확인 필요 항목 모음이 중복될 경우, 마지막 모음은 핵심 항목만 압축해 정리한다.

8. 한계 및 후속 과제

항목	내용
샘플 수	하나의 가상 회의록만 사용했으므로 일반화에는 한계가 있습니다.
모델 티어	Claude Opus와 Gemini Flash는 모델 체급이 다르므로 절대 성능 비교로 해석하면 안 됩니다.
프롬프트 조건	동일 프롬프트 1개만 사용했으므로 프롬프트 개선 후 결과는 달라질 수 있습니다.
평가 범위	최초 응답 중심 평가이며, 피드백 후 개선 능력은 별도로 비교하지 않았습니다.

후속 과제로는 짧은 회의록, 긴 회의록, 정보가 부족한 회의록을 추가 테스트하고, v2 프롬프트를 적용했을 때 모델 간 격차가 줄어드는지 확인하는 것이 좋습니다. 또한 실제 PM·기획자 관점에서 사람이 최종 회의록을 수정하는 데 걸리는 시간도 비교하면 실무 적합성을 더 객관적으로 평가할 수 있습니다.

9. 최종 결론

3개 AI 보고서를 종합하면, 최종 선정 모델은 Claude Opus 4.8로 수렴합니다. ChatGPT 5.5는 빠르고 자연스러운 회의록 초안 생성에 강점이 있고, Gemini 3.5 Flash는 간결한 구조화에는 장점이 있습니다. 그러나 본 과업의 핵심인 사실·추론 구분, 의견·결정사항 분리, Action Items의 의존관계 보존 측면에서는 Claude Opus 4.8이 가장 안정적인 결과를 보였습니다.

최종 표현

본 비교는 하나의 가상 회의록 샘플과 동일 프롬프트를 기준으로 수행한 결과입니다. 따라서 모든 업무 과업에서 Claude Opus 4.8이 항상 우수하다고 일반화할 수는 없습니다. 다만 이번 회의록 요약 및 Action Items 정리 과업에서는 사실·추론 구분, 미확정 사항 처리, Action Items 정리 품질 측면에서 Claude Opus 4.8이 가장 안정적인 결과를 보였습니다.