

LLM 모델 비교·선정 최종 통합 분석 보고서

과업: 회의 메모 → 사내 공유용 회의록 자동 요약 / 3개 AI 분석 보고서 종합

1. 종합 결론

동일한 회의록 정리 과업을 ChatGPT 5.5 · Claude Opus 4.8 · Gemini 3.5 Flash에 같은 조건으로 입력해 비교하고, 세 모델이 각각 작성한 비교·선정 보고서까지 다시 교차 검증한 결과, **최종 적용 모델은 Claude Opus 4.8로 선정한다.**

세 모델이 작성한 분석 보고서가 **독립적으로 모두 Claude를 1위로 지목**했다는 점이 이 결론의 객관성을 담보하는 핵심 근거다. 평가자이자 평가 대상인 이해충돌 구조에서도 결론이 한 방향으로 수렴했다(convergent validity). 오류 심각도를 기준으로 재조정된 통합 점수는 **Claude 4.77 > ChatGPT 4.32 > Gemini 3.82**이며, 순위와 격차 모두 명확하다.

본 과업의 핵심 변수는 문장 품질이 아니라 **결정/제안/의견/사실을 섞지 않고 분리하는 능력**이었고, 이 축에서 Claude가 가장 안정적이었다.

2. 평가 환경 (재현성 메타데이터)

항목	ChatGPT	Claude	Gemini
모델명/버전	ChatGPT 5.5	Claude Opus 4.8	Gemini 3.5 Flash
사용 채널	웹	웹	웹
사용 날짜	2026-06-08	2026-06-08	2026-06-08
요금제(무료/유료)	유료	유료	유료
주요 설정	기본값	기본값	기본값

- 제어 조건:** 세 모델 모두 유료 요금제의 웹 인터페이스에서, 다른 프로젝트 맥락이 없는 독립된 새 대화창에 동일 프롬프트·동일 회의 메모를 입력했으며, 평가는 각 모델의 출력물(최초 응답)을 기준으로 했다.

3. 평가 기준 (6개 공통 축)

사전에 확정된 6개 축으로만 정량 평가했다. 문장의 심미성보다 **사내에 즉시 공유 가능한 실무적 안정성**에 무게중심을 둔다.

평가 항목	보는 기준
정확성	회의 메모의 내용을 빠뜨리거나 왜곡하지 않았는가
형식 준수	요청한 7개 항목과 Markdown 표 형식을 지켰는가
Action Items 품질	담당 역할·작업·기한을 실무적으로 잘 나눴는가

평가 항목	보는 기준
확인 필요 항목 분리	미정/보류/추가 검토 사항을 잘 분리했는가
환각 억제	회의록에 없는 내용을 확정처럼 쓰지 않았는가
실무 활용성	실제 사내 공유용 회의록으로 바로 쓸 수 있는가

4. 최종 통합 점수표 (5점 만점)

세 분석 보고서의 점수를 단순 평균하지 않고, 반복적으로 지적된 오류의 심각도를 기준으로 재조정된 값이다.

평가 항목	ChatGPT 5.5	Claude Opus 4.8	Gemini 3.5 Flash
정확성	4.2	4.8	3.6
형식 준수	4.8	4.7	4.7
Action Items 품질	4.1	4.8	3.5
확인 필요 항목 분리	4.4	4.8	3.8
환각 억제	4.1	4.8	3.5
실무 활용성	4.3	4.7	3.8
평균	4.32	4.77	3.82

종합 순위: Claude Opus 4.8 (4.77) > ChatGPT 5.5 (4.32) > Gemini 3.5 Flash (3.82)

5. 모델별 통합 평가 (점수 근거)

Claude Opus 4.8 — 최종 선정

세 보고서 모두 1위로 평가했다. 가장 큰 강점은 회의록에서 확정된 내용과 미확정 내용을 구분하는 능력이다.

- **사실/추론 분리:** 가능한 리스크 항목 전면에 "회의 메모에 명시된 사실에서 파생되는 추론이며 확정 사항이 아님"을 명시해 환각을 차단했다.
- **의견/제안의 결정화 방지:** 퍼블리싱 담당의 "반응형+모바일 우선"을 결정사항으로 단정하지 않고 작업 의견으로 분리했고, 인증서 관리 기능은 "PM 제안 + 클라이언트 회신 대기"로 표기했다.
- **Action Items 의존성 보존:** 기한이 없는 작업에 "확인 필요"만 채우지 않고 "사이트맵 확정 후", "디자인 확정 후"처럼 업무 선후관계를 함께 표기했으며, 개발 담당 작업 2건을 모두 포함했다.
- **아쉬운 점:** 보고체("~함") 위주로 다소 경직되고, 요청 외 헤더 블록·인용구·이모지를 추가해 형식 준수에서 미세 감점(4.7).

ChatGPT 5.5 — 실용적 대안 (2위)

문서 구조화와 한국어 표현이 가장 안정적이다.

- **장점:** 7개 항목을 모두 충실히 반영했고, 지시에 없던 후속 일정 섹션을 '일정-내용' 표로 자발적으로 재구성해 가독성을 높였다.
- **아쉬운 점:** 원문에서 "이메일 발송 기능은 기본 범위에 포함 가능"이라는 개발 담당의 **설명**을, 확정된 실행 항목 ("개발 담당 - 이메일 발송 기능 구현")으로 임의 배정한 과잉 추론 오류가 있었다. 또한 확인 필요 섹션과 하단 모음의 내용이 거의 동일하게 중복된다.

Gemini 3.5 Flash — 경량 모델의 한계 (3위)

전체 구조와 형식 준수는 충족했고, 하단 모음을 [일정/기한]·[데이터] 등 카테고리 태그로 분류해 시각적 가독성은 가장 높았다.

- **핵심 감점 1 (Action 누락):** 회의 메모에 개발 범위 논의가 있었음에도, Action Items 표에서 **개발 담당 행 자체**가 통째로 누락되어 후속 업무 추적이 불가능한 결함이 발생했다.
- **핵심 감점 2 (왜곡):** 퍼블리싱 담당의 **의견**과 클라이언트 회신 대기 중인 **제안**을 공식 결정사항처럼 단정적으로 분류했다. 정확성·환각 억제 양쪽에서 감점 요인이다.
- 리스크 항목에 "추론이며 확정 아님"이라는 안전장치를 명시하지 않은 점도 차이를 만들었다.

6. 한국어 자연스러움 (보조 관찰 항목)

한국어 자연스러움은 사전 확정된 6개 공통 평가축에 포함되지 않아 정량 점수에서 제외했다. 다만 사내 공유 문서 특성상 보조적으로 검토했으며, ChatGPT가 가장 정중·자연스러운 문체, Claude는 분리 정확도는 최상이나 보고체가 다소 경직, Gemini는 간결하나 실무 판단의 세밀함이 부족했다.

본 항목을 정량 점수에서 제외한 이유: 평가 축은 사후에 임의로 추가된 것이 아니라 사전에 확정된 것이어야 근거로서 방어 가능하다. 특정 모델에 유리한 축이 뒤늦게 끼워졌다는 의심을 차단하기 위해 보조 관찰로만 다룬다.

7. 3개 분석 보고서 자체에 대한 메타 평가

각 모델이 작성한 **분석 보고서**의 신뢰도는, 자기 자신을 어떻게 채점했는지(자기평가 편향)를 기준으로 검증했다.

검증 항목	ChatGPT 분석	Claude 분석	Gemini 분석
최종 선정	Claude (일치)	Claude (일치)	Claude (일치)
자기평가 정직성	자기 2위 유지	자기 우승이나 만점 회피·자기 감점	단독본 자기 격상 → 통합본서 자진 하향
점수 변별력	좁음(관대)	넓음(엄격)	단독본 압축 → 통합본 보정
종합 신뢰도	높음	매우 높음	보통 → 통합 단계서 개선

- **수렴 검증:** 독립된 세 평가자가 모두 Claude를 1위로 지목 → "Claude가 Claude를 띄운 것"이 아니라 객관적으로 corroborate된 결론.

- **자기평가 편향:** Gemini 단독 보고서는 자기를 2위로 올리고 자신이 실패한 '환각 억제' 축에 만점을 부여했으나, 세 보고서를 함께 본 통합 단계에서는 자기 점수를 합의값으로 자진 하향했다 — 편향이 교정 가능함을 보여준다. 반대로 ChatGPT는 단독 보고서에서는 정직했으나 최종 6축 표에서 관대한 원점수로 회귀했다.
- **방법론 원칙:** 따라서 통합 점수는 개별 보고서 점수를 그대로 평균하지 않고, 반복 지적된 오류 근거를 기준으로 재조정된 값(4장)을 채택했다.

8. 최종 선정 결론 및 근거

최종 적용 모델: Claude Opus 4.8

사내 공유용 회의록은 '보기 좋은 형식'보다 '**왜곡 제로(0)의 신뢰성**'이 절대적으로 우선한다. Claude는 형식 준수에서 일부 감점(주석·이미지 과다)이 있었으나, 이는 사실 관계를 안전하게 방어하는 과정에서 발생한 트레이드오프다. 선정 근거는 다음 네 가지다.

1. **사실과 추론의 구분** — 가능한 리스크를 확정사항이 아닌 추론으로 명시하고, 메모에 없는 내용을 과도하게 확정하지 않았다.
2. **의견과 결정사항의 분리** — 퍼블리싱 담당의 의견을 결정사항으로 올리지 않고 공식 확정 여부를 확인할 항목으로 처리했다.
3. **Action Items 실무 완성도** — 기한 미정 작업에 업무 간 의존관계를 함께 표기하고 개발 작업 2건을 모두 포함했다.
4. **확인 필요 항목의 세밀함** — 인증서 포함 여부, 추가 견적, 게시판 데이터, 다국어, 관리자·호스팅 정보, 디자인·퍼블리싱 기한, 개발 일정까지 폭넓게 분리했다.

보조 결론: 신속하고 정중한 톤의 가벼운 공유가 목적이면 ChatGPT 5.5가 좋은 대안이다(단, 공유 전 Action Item의 확정 여부 검토 필요). Gemini 3.5 Flash는 누락된 개발 Action 보완·결정사항 재분류 등 사람의 개입 리스크가 커 단독 자동화 파이프라인에는 부적합하다.

일반화 제한: 본 비교는 하나의 가상 회의록 샘플과 동일 프롬프트를 기준으로 수행했다. 따라서 모든 업무 과업에서 Claude Opus 4.8이 항상 우수하다고 일반화할 수는 없다. 다만 이번 회의록 요약 및 Action Items 정리 과업에서는 사실·추론 구분, 미확정 사항 처리, Action Items 품질 측면에서 가장 안정적인 결과를 보였다.

9. 한계 및 v2 프롬프트 개선 방향

- **분석의 한계:** 단일 회의록 샘플·단일 프롬프트 기반이며, 모델 티어(상위 추론 티어 vs 속도 최적화 경량 티어)를 통제하지 않았다. 점수는 모델 계열의 절대 우열이 아니라 "동일 과업·동일 입력 조건에서의 출력 품질 비교"로 한정해 해석해야 한다.
- **후속 검증 제안:** 짧은/긴/정보 부족 회의록으로 샘플 다양화, 피드백 후 개선력 비교, 사람의 최종 수정 소요 시간 측정, 실제 PM·기획자 관점의 만족도 평가.

v2 시스템 프롬프트 가이드라인 (자가 검증 루프)

세 모델의 공통 감점 패턴이 ① 담당 역할 누락 ② 의견·제안의 결정사항 오분류에 집중되었으므로, 시스템 프롬프트에 다음 두 가이드라인을 추가해 v2로 고도화하고 재테스트한다.

...

(a) 역할 누락 방지: "최종 출력 직전, 원문 메모에 등장한 모든 담당 역할(클라이언트·PM·기획·디자인·퍼블리싱·개발)이 Action Items 표에 최소 1행 이상 포함됐는지 자체 검증하고, 누락 시 강제로행을 추가해 매핑하라."

(b) 사실/의견 분리: "회의 중 합의가 끝난 것만 결정사항에 넣고, 개인 의견이나 클라이언트 회신 대기 중인 제안 상태의 내용은 결정사항으로 단정하지 말고 '확인 필요 사항' 또는 '주석'으로 격리하라."

...

본 보고서의 채점은 원본 회의 메모, 세 모델의 출력물, 세 모델이 작성한 분석 보고서를 항목별로 교차 대조하여 작성되었으며, 모든 감점·가점 사유는 실제 출력 문구로 검증 가능하다.